

FOL 연역 사슬 — 앵커와 본 연구의 대응

각 단계는 앞 단계 + 새로운 사실 1개로부터 연역된다 · 행은 기능으로 정렬했다

★ 앵커 — arXiv:2604.18805 (2026)

FOL-1 · 과제의 형식화

8개 도메인의 과학 과제를 워크플로 실행부터
가설 주도 탐구까지 단계적으로 정의한다

FOL-2 · 자율 실행

에이전트가 도구를 호출해 과제를 끝까지
수행한다 · 25,000+ 실행

FOL-3 · 결과 채점

과제를 풀었는지를 쟀다 (outcome).
스케폴드 기여 1.5% vs 베이스 모델 41.4%

FOL-4 · 실패의 발견

증거가 68%의 트레이스에서 무시된다
반증 기반 신념 수정은 26%에서만 일어난다

FOL-5 · 판정 기준 ★ 여기가 공백

「증거를 무시했다」를 Claude Sonnet 4.5
2단계 주석 파이프라인으로 판정한다
판정자가 LLM이다 (인간 검증 일치 95.7%)

FOL-6 · 정당성의 정의

앵커에는 대응 단계가 없다.
정당함과 정확함이 분리되지 않는다

FOL-7 · 사다리

계산 수준이라는 축이 없다.
「더 계산하라」에 정답을 줄 수 없다

FOL-8 · 에스컬레이션 정답

대응 단계 없음. 관련 연구(Act or Escalate)는
임계값을 비용비에서 뺏는다

FOL-9 · 기준선

스케폴드는 설명분산의 1.5%뿐이다 —
구조를 더해도 나아지지 않는다

FOL-10 · 앵커의 결론

결과 기반 평가로는 이 실패를 탐지할 수 없다
— 무엇으로 대체할지는 열어두었다

본 연구

FOL-1 · 과제의 형식화

자연어 구조-안정성 가설을 과제로 정의한다
동일 재사용 (형식을 바꾸지 않는다)

FOL-2 · 자율 실행

실행층이 L1/L2/L3를 수행한다. 실행층은
무엇이 가설을 지지하는지 결정하지 않는다

FOL-3 · 결과 채점

방향 정확도도 쟀다 (Resolvable Accuracy).
그러나 주 지표로 쓰지 않는다

FOL-4 · 같은 실패를 계산화학에서

자기 증거가 방법오차보다 작으면 단정한다
= 과대해석 (Overinterpretation)

FOL-5 · 판정 기준 ★ 교체점

$\tau(M) = \text{GMTKN55 참조값 대비 실패 MAE}$
모델 내부가 아니라 물리 계측기에서 온다
사람도 LLM도 판정에 들어가지 않는다

FOL-6 · 정당성의 정의

$\text{Justified}(c, \Delta, M) \Leftrightarrow |\Delta| > \tau(M)$
결과가 맞아도 정당하지 않을 수 있다

FOL-7 · 사다리의 단조성

$\tau(L3) < \tau(L2) < \tau(L1)$
경험적 주장 · G2 게이트에서 검증한다

FOL-8 · 에스컬레이션의 객관적 정답

SUFFICIENT / ESCALATION / FUTILE
 $|\Delta E_{\text{ref}}|$ 와 τ 사다리만으로 결정된다 · RQ3

FOL-9 · 기준선을 한 줄 규칙으로

$R0: |\Delta E_{\text{XTB}}| \leq \tau_2 \rightarrow \text{ABSTAIN (LLM 0콜)}$
앵커의 1.5%가 R0 우세를 사전 예고한다

FOL-10 · 본 연구의 결론

$\text{Honest}(a, t) \Leftrightarrow \text{concl} = \text{CorrectAction}(t, M_{\text{used}})$
인식적 정직성이 결정 가능해진다 · RQ4

점선 상자 = 앵커에 대응 단계가 없는 곳. 본 연구가 더하는 것은 FOL-5의 판정 기준 하나이며, FOL-6~8은 거기서 따라 나온다.

조사일 2026-08-08 · 보조 앵커 arXiv:2606.23175 (Correct Answer, Wrong Mechanism)