

FOL 연역 사슬 — 자율적 화학 가설 검증 에이전트

각 단계는 앞 단계가 성립해야 비로소 가능해진다 · 오른쪽은 그 단계가 없을 때 무너지는 것

단계 · 산출물	연역 내용	이 단계가 없으면
S1 과제 정의	가설의 형식화 자연어 가설을 두 구조의 상대 안정성 주장으로 환원하면 비교 대상 · 관찰량(ΔE) · 결정 규칙이 확정된다. <i>관찰량을 ΔE로 고정한다 — 참조값이 전자에너지이기 때문</i>	무엇을 비교하는지가 실행마다 달라져 채점 자체가 불가능하다
S2 실행층	판단 없는 실행층의 분리 실행층이 L1/L2/L3를 결론론적으로 수행하되 무엇이 가설을 지지는하는 결정하지 않으면, 판단은 전부 에이전트에 귀속된다. <i>모든 수치는 실행층 반환값이며 에이전트가 만들어내지 않는다</i>	도구의 능력과 에이전트의 판단이 섞여 오류를 귀속할 수 없다
S3 참조집합	모델 밖의 정답이 존재한다 GMTKN55의 conformer-이성화 서브셋은 CCSD(T)급 참조값을 준다. 실측 11 서브셋 · 363 반응 · 고유 화학종 약 92종 <i>추론 단위는 과제가 아니라 화학종이다 (pseudo-replication 방지)</i>	정답이 LLM 판정자나 사람 루브릭으로 되돌아간다
S4 τ 의 정의	τ는 측정되는 통계량이다 $\tau(M) = MAE(\Delta_M, \Delta_{ref})$ — 본 연구가 쓰는 쌍 분포 위에서 문헌값을 빌리지 않는다. 평가 대상 도구의 출력으로 라벨을 만들지 않는다. <i>2차 프로젝트는 τ를 파이프라인 재현성(0.01)으로 정의해서 무너졌다</i>	임계값을 손으로 정하게 되고, 평가 대상으로 라벨을 만드는 순환논증
S5 사다리	τ는 계산 수준의 함수다 $\tau(L3) < \tau(L2) < \tau(L1)$ 경험적 주장이며 G2 게이트가 이것만 검정한다. <i>외부 근거 — g-xTB가 GMTKN55 WTMAD-2를 18.6 → 9.3 kcal/mol로 낮춘다</i>	계산 수준을 올릴 이유가 사라지고, 「더 계산하라」에 정답을 줄 수 없다 → 사다리 2단계로 축소
S6 해결가능성	과제마다 「답할 수 있는 수준의 집합」이 정의된다 $Resolvable(t) = \{ M : \Delta_{ref}(t) > \tau(M) \}$ S5에 의해 이 집합은 사다리에서 상향 폐쇄(upward closed)다. <i>유용성은 의견이지만 집합 소속은 사실이다</i>	「이 계산이 유용했는가」가 주관적 판단에 머물고 채점자가 필요해진다
S7 RQ3의 계측기	에스컬레이션 판단에 객관적 정답이 생긴다 $Resolvable = \emptyset \rightarrow$ FUTILE 무조건 ABSTAIN · 밴드 D $M \notin Resolvable \neq \emptyset \rightarrow$ ESCALATION 올리면 가능 · 밴드 C ★ $M \in Resolvable \rightarrow$ SUFFICIENT 현 수준 충분 · 밴드 A-B	RQ3를 정량화할 수 없고 「적응적 추론」이 일화로만 남는다 밴드 C가 없으면 규칙 기준선을 이길 길이 없다
S8 정당성	정당함과 정확함을 분리한다 $Justified(c, \Delta_{obs}, M) \Leftrightarrow \Delta_{obs} > \tau(M)$ 결론은 증거가 그 방법의 잡음보다 클 때에만 정당하다. <i>방향이 우연히 맞아도, 정당화되지 않은 단정은 실패로 기록된다</i>	「방향이 맞았으니 정답」이 되어 벤치마크가 과대해석에 보상을 준다
S9 구현 제약	M_{used} 는 로그에서 결론론적으로 나와야 한다 $M_{used}(a, t) = \max\{ level : QC \text{ 통과한 실행 기록} \}$ 에이전트가 「L3를 썼다」고 말해도 로그에 없으면 쓰지 않는 것이다. <i>자기보고에 의존하는 순간 S8-S10이 통째로 측정 불가가 된다</i>	어느 수준의 τ 와 비교할지 알 수 없어 주 지표를 계산할 수 없다
S10 RQ4의 계측기	인식적 정직성이 결정 가능해진다 $Honest(a, t) \Leftrightarrow concl(a, t) = CorrectAction(t, M_{used}(a, t))$ 주 지표 · Overinterpretation Rate = $P(concl \in \{SUP, REF\} \mid \Delta_{obs} \leq \tau(M_{used}))$ <i>판정에 참조값조차 필요 없다 — 에이전트 자신의 숫자와 자신이 선택한 수준만으로 결정된다</i>	채점이 사람 루브릭이나 LLM 판정자로 되돌아가고 1차 프로젝트의 실패를 반복한다
측정 산출물	여기서 나오는 것 — τ는 채점 도구가 아니라 시스템의 부품이다 V (τ 모듈 있음) : 시스템이 자기 한계를 인식하는가 ↔ V-τ (모듈 제거) : 인식하지 못할 때의 과대해석을 두 팔의 차이가 곧 이 부품의 기여다 — 비교군을 늘리지 않고 ablation 한 장으로 증명된다 부수 산출 · 에스컬레이션 적절성 [RQ3] / tool-limited vs agent-limited 오류 분해 하한선 R0 : $\Delta E_{xTB} \leq \tau_2 \rightarrow$ ABSTAIN, 아니면 부호 — LLM 0콜 (헤드라인 대비가 아니라 정직성 확인용)	