

논문 계보도

AI 에이전트는 계산을 수행할 뿐 아니라, 그 계산으로 답할 수 없는 질문 앞에서 멈추는가

배경 ① 계산 능력 · 자연어 → 양자화학 계산 에이전트

ChemCrow (2024) → El Agente Q (Matter 2025) → ChemGraph (Comm Chem 2025) → FermiLink · VirtualLab_CC (2026) — 계산을 끝내는 능력은 이미 확립되었다. 파이프라인 신규성은 0이다

배경 ② 연구실 형태 · **The Virtual Lab (Nature 2025)** — 역할 분리 AI 연구팀이 연구를 수행하고 웹랩으로 검증한다. 본 연구는 «연구팀» 형태를 여기서 가져오되, 웹랩을 흉내 내지 않고 계산화학 자체를 실험 공간으로 쓴다

① 무엇으로 채점하는가

El Agente Q (2025) · ChemGraph (2025)

ORCA·xTB 자율 수행 87%+ / ASE·xTB 열화학
13태스크 · 260 평가 인스턴스

채점: 인간 전문가 rubric · 최종 수치 일치

arXiv:2505.02484 · 2506.06363

MDGym (2026) · MDArena (2026)

169 MD 과제 · 3단계 난이도. 최강 에이전트가
easy 21%, 상위 <10%. 계산을 안 하고 수치를
지어내는 실패를 관찰

채점은 여전히 실행 성공률 · arXiv:2605.08941

② 모를 때 멈추는가

AgentAbstain (2026)

263 쌍 과제 · 42 실험환경 · 17 프론티어 LLM
8종 abstention 시나리오 분류

최고 모델도 60% 미만 — 멈추지 못한다

arXiv:2607.10059

Act or Escalate? (2026)

행동 vs 에스컬레이션을 비용 하의 결정으로
모델링. 5개 도메인. 암묵적 임계값이 모델마다
크게 다르고 자기추정은 miscalibrated

임계값의 출처는 열려 있다 · arXiv:2604.08588

③ 기준은 어디서 오는가

GMTKN55 (PCCP 2017) · GFN2-xTB (2019)

55 서브셋 · ~1,500 상대에너지
CCSD(T)급 참조값 — 모델 밖에 있는 정답

방법오차를 실측 가능한 양으로 만든다

Goerigk 2017 · Bannwarth 2019

g-xTB (2025) · UQ for In Silico Chemistry

GMTKN55 WTMAD-2를 18.6 → 9.3 kcal/mol로
절반. 방법을 바꾸면 오차가 바뀐다

Chem. Rev. 126, 4189 (2026)이 형식론을 정립

τ 는 상수가 아니라 방법 M 의 함수다

전부 outcome-only — 「해냈는가」만 잴다

「답할 수 없는 문제였는데 답했는가」는 재지 않는다

임계값이 전부 모델 내부에서 나온다

confidence · entropy · conformal · 질문 모호성 · 비용비

모델 밖의 기준이 이미 존재한다

그러나 에이전트 판단의 채점에 쓰인 적이 없다

τ 를 공급

★ 앵커 논문

AI scientists produce results without reasoning scientifically (2026)

8개 도메인(Corral) · 25,000+ 에이전트 실험 · 베이스 모델이 설명분산 41.4%, 스캐폴드는 1.5%

증거가 68%의 트레이스에서 무시된다 · 반증 기반 신념 수정은 26%뿐

결론: 「결과 기반 평가로는 탐지할 수 없다」 — 그러나 그 판정을 Claude Sonnet 4.5 주석으로 한다

arXiv:2604.18805 · 같은 명제: Correct Answer Wrong Mechanism (2606.23175)

공백을 메운다

본 연구 · 분자 시뮬레이션을 통한 자율적 화학 가설 검증 AI 연구 에이전트

자연어 가설 → 계산 설계·실행 → SUPPORTED / REFUTED / ABSTAIN. 만드는 것은 시스템이고, τ 는 그 시스템의 부품이다.

τ 모델 — 에이전트가 자기 방법의 오차를 알고, $|\Delta\text{자기증거}| \leq \tau(M_{\text{used}})$ 이면 결론을 유보한다 [RQ4]

사다리 — τ 가 수준의 함수이므로 SUFFICIENT / ESCALATION / FUTILE 이 기계적으로 결정된다 [RQ3]

τ 는 모델 내부가 아니라 물리 계측기의 벤치마크 오차에서 나온다. 이 부품이 값을 하는지는 ablation($-\tau$)으로 보인다