

표 S4. 벤치마크 구성 (N = 92)

(가) 구간별

구간	과제	배좌	구조	자율 식별	쌍 지정	서브셋	참조 ΔE 절댓값 범위
Band A	30	20	10	25	5	5	3.70-71.53
Band B	22	3	19	22	0	5	2.80-24.14
Band C	25	12	13	20	5	8	0.42-8.70
Band D	15	9	6	9	6	5	0.10-2.49
합계	92	44	48	76	16	8	—

(나) 서브셋별

서브셋	유형	과제	화학종	A	B	C	D
ACONF	conformer	3	3	0	0	3	0
Amino20x4	conformer	17	17	6	1	4	6
CDIE20	conformer	12	12	10	1	1	0
ICONF	conformer	7	7	4	0	1	2
ISO34	isomer	25	25	5	7	9	4
ISOL24	isomer	23	23	5	12	4	2
PCONF21	conformer	3	3	0	1	2	0
SCONF	conformer	2	2	0	0	1	1
합계	—	92	92	30	22	25	15

구간 정의

구간	조건	정답 행동
Band A	참조 ΔE 절댓값 > 3 × τ(L1)	낮은 수준으로 충분하다
Band B	τ(L1) < 참조 ΔE 절댓값 <= 3 × τ(L1)	낮은 수준으로 충분하다
Band C	τ(L3) < 참조 ΔE 절댓값 <= τ(L1)	높은 수준으로 올려야 판단할 수 있다
Band D	참조 ΔE 절댓값 <= τ(L3)	어느 수준으로도 판단할 수 없다

τ 는 반응 유형별 실측 방법 오차다(표 S2). 구간은 참조 에너지 차이의 절댓값과 τ 사다리만으로 기계적으로 정해지며 손으로 조정하지 않았다. 계산 수준을 올리는 것이 정답 행동을 바꾸는 구간은 Band C 뿐이다.

Main benchmark 는 화학종이 중복되지 않는 92과제다. 한 화학종에서 과제를 여럿 뽑지 않았으므로 추론 단위와 과제 수가 같다.

「배좌」는 conformer, 「구조」는 isomer 다. τ 가 두 유형에서 크게 달라 임계값을 따로 뒀다 (표 S2).