

표 S9. 다른 베이스 모델에서의 보조 검증 (cross-model replication)

(가) 같은 30과제에서의 결과

지표 (동일 30과제)	sonnet V	gemini V	R0
근거가 충분한 결론	21 / 30	25 / 30	18 / 30
참조값과 방향이 맞음	21 / 30	25 / 30	18 / 30
과대해석	0 / 30	0 / 30	0 / 30
과도한 신중	4 / 30	0 / 30	0 / 30
최종 판단 수준이 L3인 과제	18 / 30	16 / 30	0 / 30

(나) 사전에 지정한 검정 2개 (짜지은 정확 McNemar · 양측 · α = 0.05)

사전 지정 비교	값	불일치 (b : c)	p
sonnet V 대 R0	21 대 18	5 : 2	0.4531
sonnet V 대 gemini V	21 대 25	1 : 5	0.2188

(다) Band C — 기술 통계만 (n = 8, 검정하지 않았다)

Band C 기술 통계	sonnet V	gemini V	R0
근거가 충분한 결론	7 / 8	6 / 8	3 / 8
최종 판단 수준이 L3인 과제	8 / 8	—	—

실행 전에 정한 성공 기준은 방향 하나였고 충족됐다 — sonnet V 가 R0 보다 근거가 충분한 결론이 많다. 유의성을 조건으로 요구하지 않았다.

그 차이는 통계적으로 유의하지 않다 (p = 0.4531). 《유의하게 우수했다》 로 쓰지 않는다.

방법 오차 정보를 뺀 조건(V-τ)을 이 모델에서 돌리지 않았다 — τ 효과가 모델을 넘어 일반화된다는 주장을 하지 않는다.

두 모델 비교는 우열 연구가 아니다 (p = 0.2188).

Band C 는 검정하지 않았다. 오류 분해·과도한 신중·자율 식별은 탐색적 기술 통계다.